FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D
COIMBRA

Departamento de Engenharia Informática

Fundamentos de Inteligência Artificial
Introdução à Inteligência Artificial
2022/2023 - 2º Semestre

Trabalho Prático Nº2:
Rolling in the Hill
Evolutionary Edition

Nota: A fraude denota uma grave falta de ética e constitui um comportamento inadmissível num estudante do ensino superior e futuro profissional licenciado. Qualquer tentativa de fraude levará à anulação da componente prática tanto do facilitador como do prevaricador, independentemente de ações disciplinares adicionais a que haja lugar nos termos da legislação em vigor. Caso haja recurso a material não original, as **fontes** devem estar explicitamente indicadas.

1 Introdução

Fascinado pela forma como a Natureza resolve os problemas que encontra, o Homem usa-a frequentemente como fonte de inspiração para desenvolver soluções computacionais para problemas difíceis. É neste sentido que surgem os Algoritmos Evolucionários (AE), que são modelos computacionais inspirados na Teoria da Seleção Natural de Charles Darwin, e nos princípios de herança genética descobertos por Gregor Mendel. Estes métodos tem sido aplicados com sucesso em diversas áreas, desde otimização até ao desenho automático de antenas para satélites.

O objetivo deste trabalho passa por desenvolver as componentes de um AE para desenhar um veículo motorizado. Para isso, iremos recorrer a um simulador virtual[1], que permite avaliar o desempenho do veículo em vários cenários, nomeadamente deslocar-se em percursos com buracos, e em percursos com subidas.

O principal objetivo é que veículo seja capaz de chegar o mais longe possível no percurso onde é inserido. A Figura 1 mostra um exemplo do ambiente ambiente de simulação.

2 Enunciado

Este trabalho prático tem como objetivo principal a aquisição de competências relacionadas com a análise, desenvolvimento, implementação e teste de agentes adaptativos.

Assim, pretende-se desenvolver uma Algoritmo Evolucionário (AE) que permite o desenho de veículos para completar um conjunto de percursos. O AE irá evoluir um conjunto de parâmetros relacionados com a estrutura do veículos (e.g., número de rodas, posição das rodas, raio, etc.) de forma a melhorar a sua performance ao longo do tempo.

Os nossos veículos são formas fechadas compostas por vértices e arestas, os vértices podem ter rodas de diferentes dimensões. Há uma máximo de 14 vértices e rodas. O tamanho máximo de cada roda é 6; a distância máxima entre vértices é 80. As rodas e a estrutura do veiculo têm uma massa associada, pelo que o seu tamanho tem influência no peso do carro. Para representar o veículo descrito no nosso AE, vamos utilizar um cromossoma de números reais com a seguinte estrutura:

1. Um número real que corresponde há distancia a que se encontra o próximo vértice;

[1] O simulador é baseado na Framework GeneticSharp desenvolvida por Diego Giacomelli

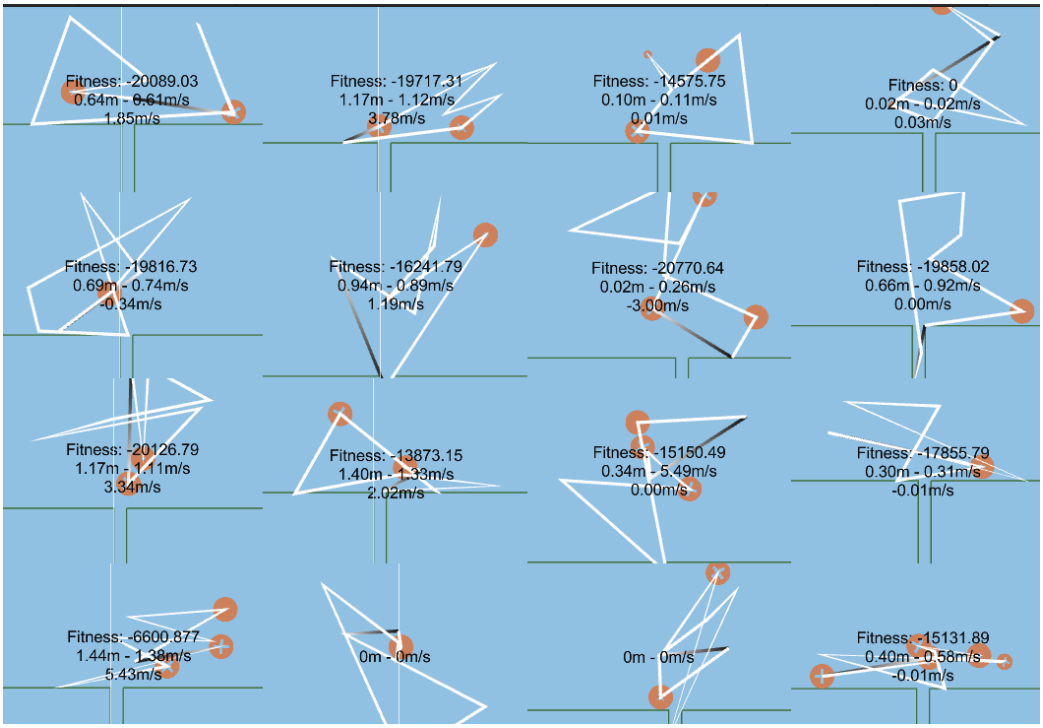

Figura 1: Exemplo do ambiente de simulação.

2. Um número real que corresponde ao ângulo para o próximo vértice;

3. O vértice onde deve ser colocada a roda;

4. Um número real que corresponde ao raio (tamanho) de cada roda;

Como o nosso veículo é composto por um máximo de 14 segmentos, temos de repetir a estrutura acima, o que resulta num cromossoma de tamanho 56.

Na prática a construção do fenótipo (indivíduo) a partir do genótipo (cromossoma) efetua-se como se segue: Primeiro constrói-se a estrutura do carro; depois adicionam-se rodas as vértices selecionados, com o raio indicado. A Fig. 2 ilustra o processo de mapeamento entre genótipo e fenótipo, assumindo um individuo com apenas 3 arestas. Note-se que a última aresta é adicionada automaticamente, para fechar a forma. A Fig. 3 apresenta um individuo mais complexo, resultado do processo evolucionário.

O mapeamento de um cromossoma para um carro está descrito na Figura 2.

De forma a permitir avaliar a qualidade de cada veículo são retiradas várias informações do ambiente de simulação, nomeadamente:

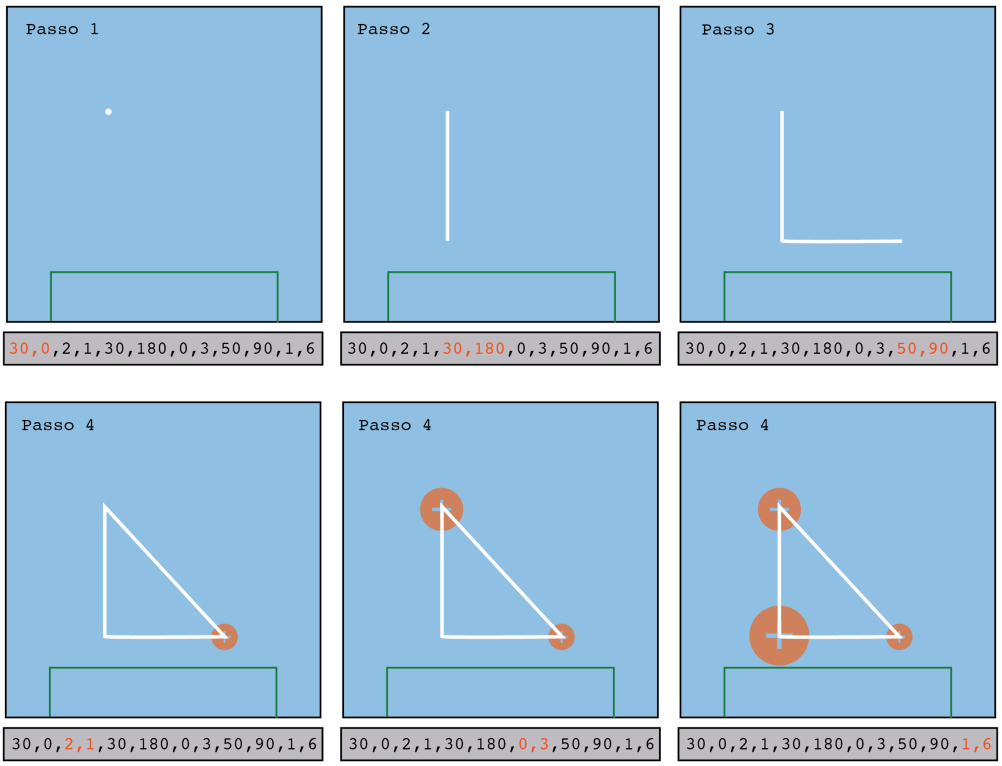

Figura 2: Mapeamento passo a passo do cromossoma para um veículo.

- Distância máxima percorrida;
- Velocidade Máxima atingida;
- Número de rodas;
- Massa do carro;
- Conseguiu chegar ao fim do percurso.

O presente trabalho prático encontra-se dividido em 2 metas distintas:

1. Meta 1 – Modelação e desenvolvimento do Algoritmo Genético.
2. Meta 2 – Experimentação e análise.

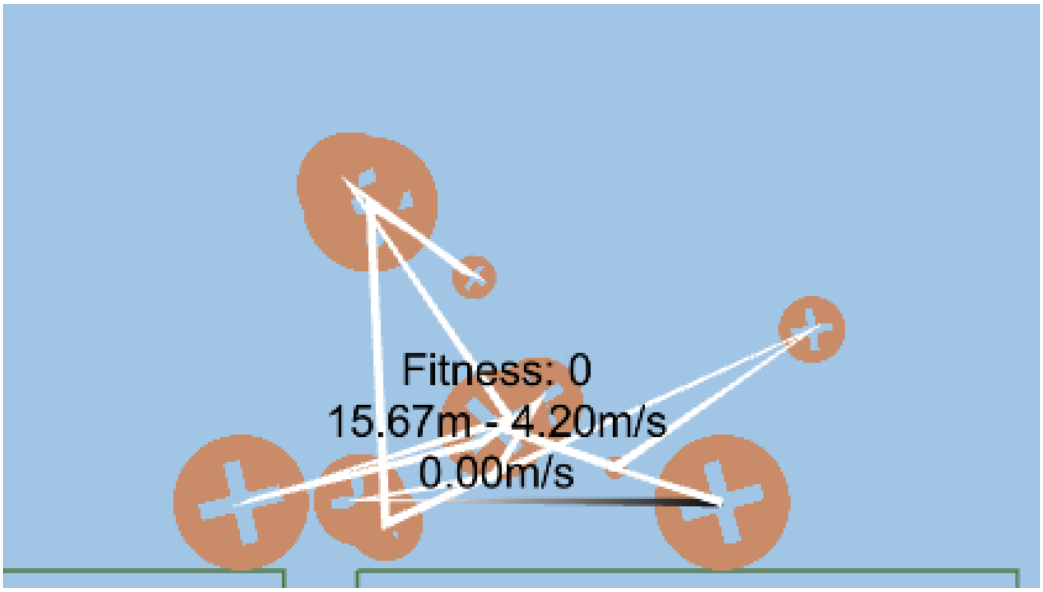

Figura 3: Fenótipo

2.1 Meta 1 – Modelação e desenvolvimento do Algoritmo Genético

A representação escolhida, os operadores genéticos, os mecanismos de seleção, a atribuição de aptidão *(fitness)*, são componentes essenciais para o bom funcionamento de um algoritmo genético. Desta forma, a etapa de **modelação** desempenha um papel fundamental no sucesso do seu algoritmo. Relativamente à representação de cada veículo, i.e., solução, o código fornecido considera que cada cromossoma é uma lista de números reais. No entanto, terá de desenvolver as restantes funcionalidades básicas do Algoritmo Genético, alterando os ficheiros que se encontram na pasta `EvolvingCars/Assets/EvolvingCars/TP2/`:

Recombinação Deve desenvolver o operador de recombinação uniforme, descrito pelo Algoritmo 1. Para isso deverá editar o ficheiro `Meta1/UniformCrossover.cs`;

Mutação Desenvolver o operador de mutação *Gaussiana* descrito pelo Algoritmo 2. Para isso deverá editar o ficheiro `Meta1/GaussiantMutation.cs`;

Seleção de Pais Deve implementar o mecanismo de **seleção por roleta**, descrito pelo Algoritmo 3. **Lembre-se que é um problema de maximização**. Para isso deverá editar o ficheiro `Meta1/Roulete.cs`;

Seleção de Sobreviventes Deve implementar o mecanismo de **Elitismo**, descrito pelo Algoritmo 4. Para isso deverá editar o ficheiro `Meta1/Elitism.cs`;

Parametrização Os parâmetros do algoritmo evolucionário – p.ex. especificar a probabilidade de mutação por gene, probabilidade de recombinação, deverão ser configurados e alterados no ficheiro `GeneticAlgorithmConfigurations.cs`;

Aptidão A aptidão de um indivíduo está relacionada com a capacidade dos veículos conseguirem chegar o mais longe possível nos cenários onde são inseridos. É por isso um **componente essencial** ao sucesso do algoritmo, e encontra-se programada no ficheiro `CarFitness.cs`. Devem ser exploradas várias funções de aptidão, tendo em conta o conjunto de informações do ambiente. Para conseguir desenvolver a sua função de aptidão terá ao dispor, em cada simulação, as seguintes informações:

1. MaxDistance - Distância máxima percorrida pelo veículo;
2. MaxDistanceTime - Tempo (em segundos) que o veículo demorou a percorrer a distância máxima;
3. MaxVelocity - Velocidade máxima atingida pelo veículo;
4. NumberOfWheels - Número de rodas que foram utilizadas pelo veículo;
5. CarMass - Massa do veículo;
6. IsRoadComplete - Indica se o veículo completou o cenário, isto é, se chegou ao fim da estrada. Tem o valor 1 se completar o cenário, e 0 caso contrário.

```
1  Function UniformCrossover(parents):
2      parent1 ← parents[0];
3      parent2 ← parents[1];
4      offspring1 ← parent1.Clone() ;
5      offspring2 ← parent2.Clone() ;
6      i ← 0 ;
7      if RandomizationProvider.Current.GetDouble() ≤
        crossoverProbability then
8          i ← 0 ;
9          for i < parent1.Length do
10             if RandomizationProvider.Current.GetDouble() ≥ 0.5
                then
11                 offspring1.ReplaceGene(i, parent2.GetGene(i));
12                 offspring2.ReplaceGene(i, parent1.GetGene(i)) ;
13             end
14             i ← i + 1 ;
15         end
16     end
```

Algoritmo 1: Pseudocódigo do Algoritmo de Crossover Uniforme. As funções RandomizationProvider.Current.GetDouble e já se encontram implementadas, e devem ser chamadas de forma como se encontra no pseudocódigo.

```
1  Function GaussianMutation(chromosome, probability):
2      i ← 0 ;
3      for i < chromosome.Length do
4          if RandomizationProvider.Current.GetDouble() ≤ probability
            then
5              geneValue = SampleGaussian((double)
                chromosome.GetGene(i).Value, std) ;
6              chromosome.ReplaceGene(i, new Gene(geneValue)) ;
7          end
8          i ← i + 1 ;
9      end
```

Algoritmo 2: Pseudocódigo do Algoritmo de mutação Gaussiana. A função RandomizationProvider.Current.GetDouble e SampleGaussian já se encontram implementadas, e devem ser chamadas de forma como se encontra no pseudocódigo.

```
1  Function Roulette(number, generation):
2      parents ← [] ;
3      sumFitness ← 0.0;
4      i ← 0 ;
5      for i < population.Count do
6          sumFitness ← sumFitness + population[i].Fitness;
7          i ← i + 1 ;
8      end
9      i ← 0 ;
10     for i < number do
11         pointer ← RandomizationProvider.Current.GetDouble();
            partial ← 0.0; index ← 0;
12         for partial ≤ pointer do
13             partial ← partial + (population[index].Fitness /
                sumFitness);
14             index ← index + 1;
15         end
16         parents.Add(population[index - 1])
17         i ← i + 1
18     end
```

Algoritmo 3: Pseudocódigo do Algoritmo de Seleção por Roleta. A função RandomizationProvider.Current.GetDouble já se encontra implementada, e devem ser chamada de forma como se encontra no pseudocódigo.

```
1  Function Elitism(population, offspring, parents):
2      i ← 0
3      for i < eliteSize do
4          offspring[i] ← old_population[i]
5          i ← i + 1
6      end
```

Algoritmo 4: Pseudocódigo do Algoritmo de Seleção de Sobreviventes com Elitismo.

Após implementadas, é vital **testar** as funcionalidades do algoritmo evolucionário por forma a garantir o seu bom funcionamento. Para isso faça uso do cenário `GapRoad`. Aqui deverá conseguir desenvolver uma função de fitness que permita ao algoritmo evolucionário encontrar um veículo capaz de chegar ao fim da estrada.

	Mutação	Elitismo	Crossover	Número Gerações
Experiência 1	0.05	0	0.9	30
Experiência 2	0.2			
Experiência 3	0.05	2		
Experiência 4	0.2			
Experiência 5	0.05			

Tabela 1: Experiências a realizar no cenário **GapRoad**. Note que, para cada experiência deverá realizar 3 execuções da mesma.

2.2 Meta 2 – Experimentação e análise

Nesta meta deve utilizar a aplicação desenvolvida para encontrar uma solução para os ambientes disponibilizados. Deve utilizar o código desenvolvido na meta anterior para evoluir os veículos. Os veículos podem ser evoluídos usando diferentes funções de aptidão adotando assim comportamentos distintos. Deve criar diversas funções de aptidão utilizando a informação disponibilizada pelo ambiente, e tentando otimizar o veículo tendo em conta diferentes parâmetros. Durante a evolução, o genótipo dos melhores veículos é guardado na pasta do projeto. Deve usar os cenários "Evaluation" para validar e testar os veículos evoluídos.

Dada a natureza estocástica das abordagens evolucionárias não é possível tirar conclusões a partir de uma única execução. Para cada combinação de parâmetros deverá realizar, pelo menos, **3** repetições da experiência para que a comparação efetuada tenha significado estatístico. **Desta forma, é importante reservar o tempo adequado para esta meta.**

Deve conduzir um conjunto alargado de experiências no cenário `GapRoad` considerando, de forma sistemática, diferentes combinações de parâmetros, nomeadamente as combinações apresentadas nas Tabela 1.

Não basta enumerar resultados experimentais, deve fazer uma análise dos mesmos procurando explicar as diferenças encontradas e os comportamentos apresentados. Para o auxiliar nesta tarefa, o simulador guarda um conjuntos de informações sobre o processo evolucionário na pasta com o nome `Results` que se encontra dentro da pasta projeto Unity. Em concreto, tem acesso a 2 ficheiros:

- `EvolutionLog.csv` - Guarda, a cada geração, as seguintes informações:
  - Generation: Número da geração;
  - BestFitness: Qualidade do melhor indivíduo;

  - AverageFitnessPopulation: Qualidade média da população;
  - BestMaxDistance: Distância máxima percorrida pelo melhor indivíduo;
  - BestMaxDistanceTime: Tempo que o melhor indivíduo demorou a percorrer a distância máxima;
  - BestNumberOfWheels: Número de rodas do melhor indivíduo;
  - BestCarMass: Massa do melhor indivíduo;
  - BestIsRoadComplete: Indica se o melhor indivíduo conseguiu, ou não, chegar ao fim da estrada.

- `OverallBestGenotype.txt` - Genótipo do melhor indivíduo. Este ficheiro poderá ser carregado nos cenários `EvaluationGap` ou `EvaluationHill` de forma a verificar o comportamento do indivíduo.

Após a avaliação das componentes do algoritmo genético deverá escolher a(s) melhor(es) combinações e aplicar as mesmas nos restantes cenários de forma a encontrar um veículo que os permita resolver.

3 Datas e Modo de Entrega

Os grupos têm uma dimensão máxima de 3 alunos. A defesa é obrigatória, bem como a presença de todos os elementos do grupo na mesma.

A entrega da meta 1 é opcional, chama-se no entanto a atenção dos alunos para a importância de concluir atempadamente esta meta. Para efeitos de nota apenas será considerada a entrega final e a defesa.

3.1 Meta 1 – Modelação e desenvolvimento

Material a entregar:

- Scripts onde implementaram e/ou alteraram código, que deve estar devidamente comentado.

- Um breve documento (max. 3 páginas), em formato pdf, com a seguinte informação:

  - Identificação dos elementos do grupo (Nomes, Números de Estudante, e-mails, Turma(s) Prática(s))
  - Informação pertinente relativamente a esta meta

Modo de Entrega:

Entrega eletrónica através do Inforestudante.
Data Limite: 16 de Abril de 2023

3.2 Meta 2 – Experimentação e análise

Tal como indicado anteriormente, esta entrega será a única que tem um impacto direto na nota. O relatório deve conter informação relativa a **todo** o trabalho realizado. Ou seja, o trabalho realizado no âmbito das metas 1 e 2 deve ser **inteiramente descrito**, por forma a possibilitar a avaliação.

Material a entregar:

- Scripts onde implementaram e/ou alteraram código, que deve estar devidamente comentado.
- Um relatório (max. 20 páginas), em formato pdf, com a seguinte informação:
  - Identificação dos elementos do grupo (Nomes, Números de Estudante, e-mails, Turma(s) Prática(s))
  - Informação pertinente relativamente à globalidade do trabalho realizado

Num trabalho desta natureza o relatório assume um papel importante. Deve ter o cuidado de descrever detalhadamente todas as funcionalidades implementadas, dando particular destaque aos problemas e soluções encontradas. Deve ser fácil ao leitor compreender o que foi feito e ter por isso capacidade de adaptar / modificar o código.

Conforme pode depreender do enunciado, **experimentação** e **análise** são parte fundamental deste trabalho prático. Assim, deve descrever de forma sucinta mas detalhada as experiências realizadas, os resultados obtidos, analisar os resultados e extrair conclusões.

O relatório deve conter informação relevante tanto da perspetiva do utilizador como do programador. Não deve ultrapassar as 20 páginas, formato A4. Todas as opções tomadas deverão ser devidamente justificadas e explicadas.

Modo de Entrega:

Entrega eletrónica através do Inforestudante.
Data Limite: 14 de Maio de 2023

4 Bibliografia

- **Inteligência Artificial: Fundamentos e Aplicações**
  Ernesto Costa, Anabela Simões
- **Artificial Intelligence: A Modern Approach**
  Stuart Russel, Peter Norvig

Checklist

Nesta secção fornece-se uma breve checklist que visa minimizar as probabilidades de lacunas graves no trabalho e relatório. Importa no entanto salientar que esta checklist **não substitui** a validação das opções tomadas, que deverá ser efetuada preferencialmente durante as aulas Práticas Laboratoriais, **nem garante** a obtenção de uma classificação final positiva.

- Implementação:
  - Implementou operador(es) de recombinação?
  - Implementou operador(es) de mutação?
  - Implementou operador(es) de seleção de progenitores?
  - Implementou operador(es) de seleção de sobreviventes?
  - Os operadores de variação preservam a validade dos indivíduos?
  - Implementou o mecanismo de seleção por roleta?
  - Teve em conta o facto de ser um problema de maximização?
  - É possível parametrizar o algoritmo?
- Experimentação:
  - As experiências realizadas têm em conta a natureza estocástica da abordagem (i.e. efetua várias repetições da experiência usando os mesmos parâmetros e seeds aleatórias distintas)?
  - Tendo em conta as opções implementadas, os resultados realizadas permitem indicar:
    - O melhor individuo para cada problema?
    - A melhor taxa de mutação mutação?
    - O impacto do elitismo na performance do algoritmo?
  - Tendo as experiências realizadas consegui evoluir agentes que permitam:
  - Terminar os cenários?
  - Qual o o tempo máximo que cada agente demora?
  - Qual o peso do veículo?
  - Qual o número de rodas do veículo?
  - As respostas às perguntas anteriores constam do relatório? Estão devidamente justificadas e suportadas em resultados experimentais?
  - No relatório, descreveu o que foi feito na meta 1 e meta 2?